

Capacità di servizio e tempi di attesa



Indice

Motivazione gestionale

Costruzione guidata del modello

Esempio svolto a mano

Caso di studio e risultati

Analisi di sensitività: il prezzo di una promessa

Esercizi

Motivazione gestionale



Introduzione: Motivazione gestionale

- ▶ In questo capitolo decidiamo **quanta capacità** assegnare a un servizio
- ▶ Classe del problema: **NLP convesso** (coda M/M/1)
- ▶ La teoria delle code dà la relazione quantitativa tra capacità e attesa
- ▶ L'ottimizzazione la trasforma in una **decisione**

Capacità contro attesa

- ▶ Quanta capacità assegnare a un servizio clienti, a uno sportello, a un servizio cloud?
- ▶ Più capacità costa; poca capacità fa **esplodere le attese**
- ▶ Ogni servizio con arrivi aleatori (call center, pronto soccorso, help desk, API di un servizio cloud) vive lo stesso dilemma: la capacità costa, l'attesa pure
- ▶ La teoria delle code dà la relazione esatta tra le due; l'ottimizzazione sceglie il punto giusto

Il messaggio centrale

Il messaggio è contro-intuitivo per chi ragiona “a efficienza”:

l'utilizzazione ottima non è il 100%

Vale da solo una discussione in consiglio di amministrazione.

In questo capitolo impareremo a

1. usare le formule M/M/1 dentro un problema di ottimizzazione
2. ricavare l'ottimo analiticamente e confermarlo numericamente
3. prezzare una promessa di servizio
4. proteggere il dimensionamento dall'incertezza sulla domanda



Riepilogo: Motivazione gestionale

- ▶ Capacità e attesa sono due costi in conflitto
- ▶ La teoria delle code li lega con formule esatte
- ▶ L'utilizzazione ottima **non** è il 100%

Costruzione guidata del modello

Introduzione: Costruzione guidata del modello

- ▶ Descriviamo il problema a parole e fissiamo i dati
- ▶ Introduciamo la variabile decisionale: la capacità μ
- ▶ Scriviamo il modello di costo totale e lo risolviamo in **forma chiusa**

Il problema a parole

- ▶ *Decidiamo* quanta capacità di servizio acquistare
- ▶ *L'obiettivo* è minimizzare il costo totale: capacità comprata più il valore del tempo che i clienti passano nel sistema
- ▶ *Il vincolo* strutturale è uno solo: la stabilità della coda ($\mu > \lambda$)
- ▶ Nelle varianti si aggiunge la promessa di servizio $w \leq w_{\max}$

La coda M/M/1

- ▶ Usiamo il modello di coda più semplice, in notazione standard **M/M/1**:
 - ▶ arrivi *markoviani* (processo di Poisson)
 - ▶ tempi di servizio *markoviani* (esponenziali)
 - ▶ *un* servente
- ▶ Per questo sistema valgono formule chiuse
- ▶ Ciò che qui è nuovo: trattare la capacità μ come una **variabile di ottimizzazione**

Dati (input del modello)

Simbolo	Tipo	Significato
λ	$\in \mathbb{Q}_{>0}$	tasso medio di arrivo dei clienti (richieste/ora)
c	$\in \mathbb{Q}_{>0}$	costo di un'unità di capacità (€ per unità di μ all'ora)
h	$\in \mathbb{Q}_{>0}$	valore di un'ora di permanenza di un cliente nel sistema (€)

Variabile decisionale e grandezze derivate

- Introduciamo una variabile continua:

μ = capacità del servizio (tasso di servizio, richieste/ora)

con il requisito di stabilità $\mu > \lambda$

- Tempo medio nel sistema (in letteratura: W):

$$w(\mu) = \frac{1}{\mu - \lambda}$$

- Numero medio di clienti nel sistema (legge di Little; in letteratura: L):

$$l(\mu) = \frac{\lambda}{\mu - \lambda}$$

Il modello

Usando questa variabile, il modello per il problema è il seguente:

Definizione 1: Modello di costo totale capacità + attesa

$$\min \quad c\mu + h \frac{\lambda}{\mu - \lambda}$$

soggetto a $\mu > \lambda$

Funzione obiettivo e vincolo

- ▶ La funzione obiettivo è la somma di due termini:
 - ▶ $c \mu$ compra la capacità
 - ▶ $h \cdot I(\mu)$ monetizza il tempo complessivo che i clienti passano nel sistema
- ▶ L'obiettivo è **convesso** su $(\lambda, +\infty)$
- ▶ Il vincolo $\mu > \lambda$ definisce la variabile e garantisce la stabilità della coda: con $\mu \leq \lambda$ la fila cresce senza limite

Soluzione in forma chiusa

Annullando la derivata dell'obiettivo si ottiene:

$$C'(\mu) = c - \frac{h\lambda}{(\mu - \lambda)^2} = 0$$

$$\Rightarrow \boxed{\mu^* = \lambda + \sqrt{h\lambda/c}}$$

Capacità = domanda + scorta di sicurezza

- ▶ La formula ha la struttura classica “capacità = domanda + scorta di sicurezza”
- ▶ Si copre la domanda media λ e si aggiunge un margine $\sqrt{h\lambda/c}$
- ▶ Il margine cresce con il valore del tempo dei clienti e decresce con il costo della capacità
- ▶ Il margine cresce come $\sqrt{\lambda}$: i sistemi grandi godono di economie di scala nel “cuscinetto” (**pooling**)

Riepilogo: Costruzione guidata del modello

- ▶ Una sola variabile continua: la capacità $\mu > \lambda$
- ▶ Costo totale $c\mu + h\lambda/(\mu - \lambda)$, convesso
- ▶ Ottimo in forma chiusa: $\mu^* = \lambda + \sqrt{h\lambda/c}$
- ▶ Il margine di sicurezza cresce come $\sqrt{\lambda}$ (pooling)

Esempio svolto a mano

Introduzione: Esempio svolto a mano

- ▶ Applichiamo la formula di μ^* a un piccolo sportello
- ▶ Calcoliamo utilizzazione, tempo medio e costo all'ottimo
- ▶ Vediamo perché “tagliare la capacità” è una cattiva idea

Esempio: sportello con 8 clienti l'ora (1/2)

Dati: $\lambda = 8/h$, $c = 2 \text{ €}$ per unità di capacità, $h = 4 \text{ €/h}$.

► **Passo 1.**

$$\mu^* = 8 + \sqrt{4 \cdot 8/2} = 8 + 4 = 12 \text{ clienti/ora}$$

► **Passo 2.** Utilizzazione $\rho = 8/12 = 66,7\%$

► Tempo medio $w = 1/(12 - 8) = 15 \text{ minuti}$

► Costo $C = 2 \cdot 12 + 4 \cdot 8/4 = 32 \text{ €/h}$

Esempio: sportello con 8 clienti l'ora (2/2)

- ▶ **Passo 3 — perché non tagliare la capacità?**
- ▶ Con $\mu = 9$ ($\rho = 89\%$, “più efficiente”):

$$C = 18 + 32/1 = 50 \text{ €/h}$$

molto peggio

- ▶ L'apparente spreco (33% di capacità inutilizzata) è ciò che tiene corte le code

Riepilogo: Esempio svolto a mano

- ▶ All'ottimo: $\mu^* = 12$, $\rho = 66,7\%$, $w = 15$ minuti, $C = 32$ €/h
- ▶ Aumentare l'utilizzazione all'89% fa salire il costo a 50 €/h
- ▶ La capacità inutilizzata non è spreco: tiene corte le code

Caso di studio e risultati

Introduzione: Caso di studio e risultati


- ▶ Un servizio clienti: $\lambda = 42$ richieste/ora, $c = 3$ €, $h = 1,5$ €
- ▶ Confrontiamo la soluzione analitica con quella di Gurobi
- ▶ Guardiamo i due grafici chiave: costo totale e “muro dell'utilizzazione”

Risultati

Servizio clienti: $\lambda = 42$ richieste/ora, $c = 3$ €, $h = 1,5$ €.

```
Analitico : mu* = 42 + sqrt(1,5*42/3) = 46,583  
           costo 153,495 EUR/h  
Gurobi    : mu* = 46,582 (bilineare w(mu-lam) = 1,  
           NonConvex=2: coincide)  
All'ottimo: rho = 90,2%   w = 13,1 minuti
```


Il costo totale è convesso in μ



Lettura del grafico

- ▶ Il costo di capacità $c\mu$ è crescente
- ▶ Il costo di attesa $h\lambda/(\mu - \lambda)$ è decrescente
- ▶ La loro somma, il costo totale, è convessa
- ▶ Il minimo è in $\mu^* = 46,6$

Il muro dell'utilizzazione



Oltre il 90% l'attesa esplode in modo iperbolico.

Insight manageriale

- ▶ Il muro dell'utilizzazione è forse il grafico più importante da mostrare a un manager
- ▶ Tra $\rho = 90\%$ e $\rho = 99\%$ il tempo di attesa si moltiplica per dieci
- ▶ “Saturare le risorse” e “dare un buon servizio” sono obiettivi in conflitto **matematico**, non organizzativo
- ▶ Nessuna riorganizzazione elimina l'iperbole $w = 1/(\mu - \lambda)$

Riepilogo: Caso di studio e risultati

- ▶ Ottimo: $\mu^* = 46,58$, costo 153,50 €/h; Gurobi conferma
- ▶ All'ottimo $\rho = 90,2\%$ e $w = 13,1$ minuti
- ▶ Vicino al 100% di utilizzazione l'attesa esplode: saturare le risorse e servire bene sono in conflitto

Analisi di sensitività: il prezzo di una promessa



Introduzione: il prezzo di una promessa


- ▶ Il marketing promette un tempo medio sotto una soglia $w_{\max}$
- ▶ Quanto costa mantenere questa promessa?
- ▶ Calcoliamo il costo marginale della promessa (prezzo ombra)
- ▶ Infine proteggiamo il dimensionamento dall'incertezza su λ (robustezza)

La promessa di servizio

- ▶ Per avere “tempo medio sotto $w_{\max}$ ” serve $\mu \geq \lambda + 1/w_{\max}$
- ▶ Il vincolo diventa attivo quando è più stringente dell’ottimo economico (13,1 minuti)

w_max = 12 min:	mu = 47,00	costo 153,60	(quasi gratis)
w_max = 9 min:	mu = 48,67	costo 155,45	
w_max = 6 min:	mu = 52,00	costo 162,30	
w_max = 4 min:	mu = 57,00	costo 175,20	
w_max = 3 min:	mu = 62,00	costo 189,15	
w_max = 2 min:	mu = 72,00	costo 218,10	(+42% sul costo base)

Quanto costa una promessa di servizio più ambiziosa



Lettura del grafico

- ▶ L'asse è invertito: verso destra la promessa diventa più ambiziosa
- ▶ La linea tratteggiata è il costo senza promessa
- ▶ Fino a 12 minuti la promessa è quasi gratuita
- ▶ Sotto i 4 minuti ogni minuto in meno costa in modo esplosivo

Il costo marginale della promessa (1/2)

- ▶ Il prezzo ombra del vincolo cresce in modo esplosivo:
 - ▶ da 12 a 9 minuti costa 1,85 €/h
 - ▶ da 3 a 2 minuti costa 28,95 €/h
- ▶ Quando il vincolo è attivo, $\mu = \lambda + 1/w_{\max}$ e

$$C = c\lambda + c/w_{\max} + h\lambda w_{\max}$$

- ▶ Da cui (con $w_{\max}$ in ore):

$$\frac{dC}{dw_{\max}} = -\frac{c}{w_{\max}^2} + h\lambda$$

Il costo marginale della promessa (2/2)

- ▶ A $w_{\max} = 6$ minuti vale

$$-300 + 63 = -237 \text{ €/h per ora di promessa}$$

esattamente la stima per differenze finite dello script

- ▶ È il numero da dare al marketing *prima* che firmi lo SLA
- ▶ SLA = *Service Level Agreement*, l'impegno contrattuale sul livello di servizio

- ▶ Se λ è incerto in $[36, 48]$, dimensionare sull'ottimo nominale $\mu^* = 46,58$ è **instabile**
- ▶ Con $\lambda = 48 > \mu^*$ la coda diverge (costo infinito)
- ▶ Minimizzare il costo del caso peggiore dà $\mu_{\text{rob}} = 52,90$, con costo worst-case 173,39 €/h
- ▶ Si paga un premio assicurativo di $\approx 13\%$ per essere protetti da un disastro
- ▶ Le decisioni di capacità vanno sempre verificate contro il *massimo* plausibile della domanda, non solo contro la media

Riepilogo: il prezzo di una promessa

- ▶ Una promessa $w \leq w_{\max}$ impone $\mu \geq \lambda + 1/w_{\max}$
- ▶ Il costo marginale $dC/dw_{\max} = -c/w_{\max}^2 + h\lambda$ esplode per promesse ambiziose
- ▶ Dimensionare sulla domanda media può rendere la coda instabile
- ▶ La soluzione robusta costa circa il 13% in più e protegge dal disastro



Esercizi

Introduzione: Esercizi

- ▶ Quattro esercizi per consolidare i concetti del capitolo
- ▶ Verifica del costo marginale, penalità quadratica, pooling, frontiera capacità-servizio
- ▶ Si risolvono con le formule viste e con lo script del laboratorio

Esercizio: verifica

- Ricavare per conto proprio la formula

$$\frac{dC}{dw_{\max}} = -\frac{c}{w_{\max}^2} + h\lambda$$

- Verificarla numericamente a $w_{\max} = 4$ e 9 minuti con differenze finite

Esercizio: penalità quadratica

- Sostituire il costo d'attesa lineare con

$$h \left[\frac{1}{\mu - \lambda} \right]^2$$

- Ricavare μ^* analiticamente
- Confrontare l'utilizzazione ottima con il caso lineare

Esercizio: due code contro una

- ▶ Due sportelli separati ricevono $\lambda = 21$ ciascuno
- ▶ In alternativa, un unico sistema riceve $\lambda = 42$ con capacità aggregata
- ▶ A parità di costo di capacità, quale configurazione dà attese minori?
- ▶ È l'argomento quantitativo per il **pooling**

Esercizio: frontiera capacità-servizio

- ▶ Tracciare la frontiera (costo, w) variando $w_{\max}$ con continuità
- ▶ Individuare il punto oltre il quale ogni minuto promesso in meno costa più di 10 €/h

Riepilogo (1/2)

Modello:

- ▶ Coda M/M/1, capacità μ come variabile, vincolo di stabilità $\mu > \lambda$
- ▶ Costo totale $c\mu + h\lambda/(\mu - \lambda)$, convesso
- ▶ Ottimo $\mu^* = \lambda + \sqrt{h\lambda/c}$: domanda + scorta di sicurezza

Messaggio manageriale:

- ▶ L'utilizzazione ottima non è il 100%
- ▶ Vicino alla saturazione l'attesa esplode (muro dell'utilizzazione)

Riepilogo (2/2)

Promesse di servizio:

- ▶ $w \leq w_{\max}$ diventa $\mu \geq \lambda + 1/w_{\max}$
- ▶ Il prezzo ombra esplode per promesse ambiziose: calcolarlo prima di firmare lo SLA

Robustezza:

- ▶ Dimensionare sulla domanda massima plausibile, non solo sulla media
- ▶ Il premio assicurativo ($\approx 13\%$) evita la divergenza della coda