

Support Vector Machine



Indice

Motivazione gestionale

Hard margin: la geometria

Soft margin

La formulazione duale e i support vector

Kernel: frontiere non lineari da un QP convesso

Classi sbilanciate e costi asimmetrici

Support Vector Regression

Esercizi

Motivazione gestionale



Introduzione: Motivazione gestionale

- ▶ La Support Vector Machine collega direttamente l'ottimizzazione convessa al machine learning
- ▶ Il classificatore si ottiene risolvendo un **QP**, con una lettura geometrica chiara
- ▶ Applicazioni gestionali immediate: rischio di credito, churn, manutenzione predittiva, controllo qualità, frodi

Nessuna libreria di machine learning

- ▶ In questo capitolo *non* usiamo librerie di ML: ogni modello è un QP scritto e risolto con Gurobi
- ▶ L'obiettivo è capire *che cosa* ottimizza un classificatore
- ▶ **Nota modellistica:** le etichette $y_i \in \{-1, +1\}$ sono *dati osservati*, non variabili
- ▶ Le variabili (coefficienti, intercetta, scarti, moltiplicatori) sono tutte continue

Il capitolo chiude il cerchio

- ▶ Gli stessi strumenti usati per produzione, logistica e finanza — QP convessi, dualità, moltiplicatori — sono il motore di uno dei classificatori più eleganti del machine learning
- ▶ Capire la SVM come problema di ottimizzazione, e non come scatola nera di libreria, dà il controllo completo su ciò che il modello sta davvero facendo

In questo capitolo impareremo a

1. formulare hard e soft margin come QP
2. derivare e risolvere il duale, identificando i support vector
3. ottenere frontiere non lineari con i kernel restando nel mondo convesso
4. gestire classi sbilanciate con costi asimmetrici e valutare con le metriche giuste

Riepilogo

- ▶ La SVM è un classificatore ottenuto risolvendo un QP convesso
- ▶ Le etichette y_i sono dati; tutte le variabili sono continue
- ▶ Ogni modello del capitolo è scritto e risolto con Gurobi, senza librerie di ML

Hard margin: la geometria

Introduzione: Hard margin

- ▶ Partiamo dal caso più semplice: due classi separabili da un iperpiano
- ▶ Tra tutti gli iperpiani separatori cerchiamo quello con il **margin**e più ampio
- ▶ Vedremo che massimizzare il margine è un QP convesso con vincoli lineari

Il problema a parole

- ▶ *Decidiamo* i coefficienti di un iperpiano che separi due classi di osservazioni
- ▶ *L'obiettivo* è massimizzare il margine, cioè la distanza tra l'iperpiano e i punti più vicini delle due classi (un classificatore con margine ampio generalizza meglio)
- ▶ *I vincoli* chiedono che ogni osservazione stia dal lato giusto dell'iperpiano — nel soft margin, a meno di uno scarto pagato in obiettivo

Dati (input del modello) (1/2)

Simbolo	Tipo	Significato
n	$\in \mathbb{Z}_{\geq 1}$	numero di osservazioni del training set, indicizzate da $i \in \{1, \dots, n\}$
p	$\in \mathbb{Z}_{\geq 1}$	numero di caratteristiche, indicizzate da $j \in \{1, \dots, p\}$
x_{ij}	$\in \mathbb{Q}$	valore della caratteristica j per l'osservazione i ; $\mathbf{x}_i \in \mathbb{Q}^p$ è il vettore dell'osservazione i

Dati (input del modello) (2/2)

Simbolo	Tipo	Significato
y_i	$\in \{-1, +1\}$	etichetta <i>osservata</i> della classe di i (un dato, non una variabile)
C	$\in \mathbb{Q}_{>0}$	peso delle violazioni del margine (solo soft margin)

- C è maiuscolo per aderenza alla letteratura di machine learning: un'eccezione alla convenzione che riserva le maiuscole a insiemi e matrici

Variabili decisionali

Introduciamo le seguenti $p + 1$ variabili libere:

$$\begin{cases} w_j = \text{coefficiente } j \text{ dell'iperpiano separatore} \\ b = \text{intercetta dell'iperpiano} \end{cases} \quad \forall j \in \{1, \dots, p\}$$

Esse definiscono l'iperpiano

$$\sum_{j=1}^p w_j x_j + b = 0$$

Modello QP hard margin

Modello QP hard margin

$$\min \quad \frac{1}{2} \sum_{j=1}^p w_j^2 \quad (15.1a)$$

$$\text{soggetto a} \quad y_i \left(\sum_{j=1}^p w_j x_{ij} + b \right) \geq 1, \quad \forall i \in \{1, 2, \dots, n\}, \quad (15.1b)$$

$$w_j \geq 0, \quad \forall j \in \{1, 2, \dots, p\}, \quad (15.1c)$$

$$b \geq 0. \quad (15.1d)$$

Descrizione del modello QP hard margin

- ▶ La funzione obiettivo quadratica convessa minimizza $\frac{1}{2} \|\mathbf{w}\|^2$: poiché il margine geometrico tra gli iperpiani di supporto è $2/\|\mathbf{w}\|$, minimizzarla equivale a *massimizzare il margine*
- ▶ I vincoli lineari di classificazione impongono che ogni osservazione stia dal lato giusto dell'iperpiano, a distanza almeno unitaria in scala $\mathbf{w}$ (n vincoli lineari)
- ▶ Gli ultimi vincoli definiscono le variabili del modello, tutte libere

Esempio: Due punti, tutto a mano (1/3)

► $\mathbf{x}_1 = (0, 0)$ con $y_1 = -1$ e $\mathbf{x}_2 = (2, 2)$ con $y_2 = +1$

Passo 1 — vincoli

$$-(b) \geq 1 \quad \text{e} \quad 2w_1 + 2w_2 + b \geq 1$$

cioè

$$b \leq -1 \quad \text{e} \quad 2(w_1 + w_2) \geq 1 - b \geq 2$$

Esempio: Due punti, tutto a mano (2/3)

Passo 2 — simmetria e ottimo

- ▶ Per minimizzare $w_1^2 + w_2^2$ con $w_1 + w_2 \geq 1$ conviene $w_1 = w_2 = t$ e prendere le disuguaglianze attive:

$$4t + b = 1, \quad b = -1 \quad \Rightarrow \quad t = 1/2$$

- ▶ Quindi $\mathbf{w} = (0,5; 0,5)$ e $b = -1$
- ▶ L'iperpiano $0,5x_1 + 0,5x_2 = 1$ è l'asse del segmento tra i due punti

Esempio: Due punti, tutto a mano (3/3)

Passo 3 — margine

$$\frac{2}{\|\mathbf{w}\|} = \frac{2}{\sqrt{0,5}} = 2\sqrt{2} = 2,83$$

- ▶ È esattamente la distanza tra i due punti
- ▶ Entrambi i vincoli sono attivi: entrambi i punti sono *support vector*
- ▶ Con dati reali sovrapposti, però, l'hard margin è inammissibile: serve il soft margin

Riepilogo

- ▶ L'hard margin cerca l'iperpiano separatore di margine massimo
- ▶ Margine = $2/\|\mathbf{w}\|$: massimizzarlo equivale a minimizzare $\frac{1}{2}\|\mathbf{w}\|^2$
- ▶ È un QP convesso con n vincoli lineari e $p + 1$ variabili libere
- ▶ I punti con vincolo attivo sono i *support vector*
- ▶ Con classi sovrapposte il modello è inammissibile

Soft margin

Introduzione: Soft margin

- ▶ Con dati reali sovrapposti l'hard margin è inammissibile
- ▶ Permettiamo ad alcune osservazioni di violare il margine, pagando la violazione in obiettivo
- ▶ Il parametro C governa il compromesso tra margine ampio e aderenza ai dati

Variabili di scarto

Si aggiungono n variabili non negative di scarto:

$\xi_i =$ violazione del margine dell'osservazione i , $\forall i \in \{1, \dots, n\}$

- ▶ $\xi_i = 0$: l'osservazione rispetta il margine
- ▶ $\xi_i > 1$: l'osservazione è classificata in modo errato

Modello QP soft margin (primale)

Modello QP soft margin (primale)

$$\min \quad \frac{1}{2} \sum_{j=1}^p w_j^2 + C \sum_{i=1}^n \xi_i \quad (15.2a)$$

$$\text{soggetto a} \quad y_i \left(\sum_{j=1}^p w_j x_{ij} + b \right) \geq 1 - \xi_i, \quad \forall i \in \{1, 2, \dots, n\}, \quad (15.2b)$$

$$w_j \geq 0, \quad \forall j \in \{1, 2, \dots, p\}, \quad (15.2c)$$

$$b \geq 0, \quad (15.2d)$$

$$\xi_i \geq 0, \quad \forall i \in \{1, 2, \dots, n\}. \quad (15.2e)$$

Descrizione del modello QP soft margin


- ▶ La funzione obiettivo quadratica convessa bilancia due termini:
 - ▶ la semplicità del modello ($\frac{1}{2}\|\mathbf{w}\|^2$, margine ampio)
 - ▶ il costo delle violazioni sul training set ($C \sum_i \xi_i$)
- ▶ C è il prezzo assegnato alle violazioni
- ▶ I vincoli lineari richiedono la classificazione corretta *a meno dello scarto* ξ_i , pagato in obiettivo (n vincoli lineari)
- ▶ Variabili: w_j e b libere, ξ_i non negative

Caso di studio: rischio di credito

- ▶ 90 clienti, due indicatori standardizzati: solidità patrimoniale e puntualità nei pagamenti
- ▶ 55 affidabili e 35 insolventi, parzialmente sovrapposti

C	w	b	margine	errori	nel margine
0,05	(0,678; 0,474)	-0,148	2,418	2	22
1,00	(1,433; 0,611)	-0,236	1,284	2	7
20,00	(5,058; 2,338)	-2,936	0,359	0	3

Soft margin: iperpiano, margine e support vector ($C = 1$)



Come leggere il grafico

- ▶ I 90 clienti nel piano dei due indicatori: affidabili (teal), insolventi (rosso), support vector cerchiati in verde
- ▶ La retta nera è l'iperpiano ottimo per $C = 1$ con le sue rette di margine (tratteggiate)
- ▶ Le rette grigia e arancione sono gli iperpiani per $C = 0,05$ (margine ampio) e $C = 20$ (margine stretto)

Il compromesso regolarizzazione–aderenza

- ▶ C piccolo compra un margine ampio accettando 22 punti dentro il margine
- ▶ C grande insegue ogni punto del training set (zero errori, margine strettissimo)
- ▶ È il compromesso **regolarizzazione–aderenza**: C va scelto con dati di validazione, mai guardando il test set
- ▶ Le tre rette sono simili ma non uguali: la pendenza cambia perché i punti “pagati” cambiano

Riepilogo

- ▶ Il soft margin aggiunge gli scarti $\xi_i \geq 0$, pagati C ciascuno in obiettivo
- ▶ Resta un QP convesso, sempre ammissibile
- ▶ C piccolo: margine ampio, più violazioni; C grande: margine stretto, aderenza al training set
- ▶ C si sceglie con dati di validazione, mai con il test set

La formulazione duale e i support vector

Introduzione: La formulazione duale

- ▶ Associamo un moltiplicatore a ogni vincolo di classificazione e scriviamo il duale del soft margin
- ▶ Il duale rivela quali osservazioni determinano davvero la frontiera: i **support vector**
- ▶ Il duale dipende dai dati solo tramite prodotti scalari: è la porta verso i kernel

Moltiplicatori

Associando un moltiplicatore α_i a ciascun vincolo di classificazione del soft margin, si ottengono n nuove variabili:

α_i = moltiplicatore del vincolo di classificazione dell'osservazione i

$$\forall i \in \{1, 2, \dots, n\}$$

Modello QP duale del soft margin

Modello QP duale del soft margin

$$\max \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i' \mathbf{x}_j \quad (15.3a)$$

$$\text{soggetto a } \sum_{i=1}^n \alpha_i y_i = 0, \quad (15.3b)$$

$$\alpha_i \leq C, \quad \forall i \in \{1, 2, \dots, n\}, \quad (15.3c)$$

$$\alpha_i \geq 0, \quad \forall i \in \{1, 2, \dots, n\}. \quad (15.3d)$$

Descrizione del modello duale

- ▶ La funzione obiettivo quadratica concava dipende dai dati *solo* tramite i prodotti scalari $\mathbf{x}_i' \mathbf{x}_j$: è l'osservazione che apre la porta al kernel
- ▶ Il vincolo lineare $\sum_i \alpha_i y_i = 0$ deriva dalla stazionarietà rispetto all'intercetta b (un vincolo lineare)
- ▶ I vincoli $\alpha_i \leq C$ limitano ogni moltiplicatore al prezzo C delle violazioni (n vincoli lineari)
- ▶ I vincoli $\alpha_i \geq 0$ definiscono le variabili del modello

Relazione primale-duale

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \qquad f(\mathbf{x}) = \text{sign}(\mathbf{w}'\mathbf{x} + b)$$

Sul caso del rischio di credito ($C = 1$):

- ▶ $\mathbf{w}$ dal duale = (1,433; 0,611), $b = -0,236$: identici al primale
- ▶ valore duale 4,7868 = valore primale (dualità forte)

moltiplicatore	punti	significato
$\alpha_i = 0$	83	NON influenzano la frontiera
$0 < \alpha_i < C$	2	esattamente sul margine
$\alpha_i = C$	5	dentro il margine o mal classificati

Perché si chiamano support vector (1/2)

- ▶ La soluzione dipende *solo* dai 7 punti con $\alpha_i > 0$: sono loro a “sostenere” l’iperpiano
- ▶ Gli altri 83 potrebbero sparire senza cambiare nulla
- ▶ Il duale, inoltre, dipende dai dati solo tramite i prodotti scalari $\mathbf{x}'_i \mathbf{x}_j$: questa osservazione apre la porta al kernel

Perché si chiamano support vector (2/2)

La complementarità KKT organizza tutto:

- ▶ $\alpha_i = 0 \Rightarrow$ punto oltre il margine
- ▶ $0 < \alpha_i < C \Rightarrow$ esattamente sul margine (da questi si ricava b)
- ▶ $\alpha_i = C \Rightarrow$ il vincolo “paga” scarto $\xi_i > 0$

Riepilogo

- ▶ Il duale ha una variabile $\alpha_i \in [0, C]$ per ogni osservazione
- ▶ $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$: la frontiera dipende solo dai punti con $\alpha_i > 0$, i support vector
- ▶ Dualità forte: valore duale = valore primale
- ▶ I dati entrano nel duale solo tramite i prodotti scalari $\mathbf{x}_i' \mathbf{x}_j$

Kernel: frontiere non lineari da un QP convesso

Introduzione: Kernel

- ▶ Non tutte le classi si separano con una retta
- ▶ Sfruttando il duale, sostituiamo il prodotto scalare con un **kernel**
- ▶ Otteniamo frontiere curve restando in un QP convesso

Il kernel RBF

- Sostituiamo $\mathbf{x}_i' \mathbf{x}_j$ con un kernel $K(\mathbf{x}_i, \mathbf{x}_j)$, ad esempio il kernel RBF (*Radial Basis Function*) gaussiano

$$K(\mathbf{x}, \mathbf{z}) = e^{-\gamma \|\mathbf{x} - \mathbf{z}\|^2}$$

- Si classifica in uno spazio trasformato senza mai costruirlo:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^n \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b \right)$$

- La frontiera può essere arbitrariamente curva, ma il training *resta un QP convesso* se il kernel è valido (matrice semidefinita positiva)


Caso di studio: anomalie “a corona”

- ▶ 90 osservazioni di processo
- ▶ Il funzionamento normale al centro, le anomalie disposte ad anello
- ▶ Nessuna retta può separarle

γ	errori di training	support vector
0,1	1	20
0,7	0	15
5,0	0	61

Con $\gamma = 5$ il modello “memorizza” i punti.

Kernel RBF: la frontiera di livello 0



Come leggere il grafico

- ▶ Il dataset “a corona”: funzionamento normale al centro, anomalie ad anello
- ▶ Le curve sono le frontiere di decisione del kernel RBF per tre valori di γ
- ▶ Con $\gamma = 0,1$ la frontiera è un cerchio regolare
- ▶ Con $\gamma = 5$ si frammenta intorno ai singoli punti (overfitting)

Osservazione 1: Convessità non vuol dire generalizzazione

Con $\gamma = 5$ la frontiera si frammenta in isole intorno ai singoli punti e i support vector salgono a 61 su 90: il modello sta memorizzando il training set (overfitting), pur restando un QP convesso.

Convessità del training e capacità di generalizzare sono proprietà diverse. C e γ vanno scelti insieme per cross-validation.

Riepilogo

- ▶ Il kernel sostituisce il prodotto scalare nel duale: frontiere non lineari senza costruire lo spazio trasformato
- ▶ Con un kernel valido il training resta un QP convesso
- ▶ γ grande: frontiera frammentata, molti support vector, overfitting
- ▶ C e γ si scelgono insieme per cross-validation

Classi sbilanciate e costi asimmetrici

Introduzione: Classi sbilanciate

- ▶ Nelle applicazioni gestionali la classe importante è rara
- ▶ L'errore sui rari costa di più (un insolvente non individuato, una frode non scoperta)
- ▶ Vediamo come incorporare costi asimmetrici nel modello

Pesare gli scarti

Basta pesare gli scarti in modo diverso per le due classi:

$$C_- \sum_{i: y_i = -1} \xi_i + C_+ \sum_{i: y_i = +1} \xi_i$$

	precision	recall insolventi
costi uguali ($C = 1$)	1,00	0,94
costo $10\times$ sugli insolventi	0,97	1,00

Costi decisionali, non frequenze

- ▶ Con il costo $10\times$ la frontiera arretra verso la classe “sana”
- ▶ Nessun insolvente sfugge (recall 100%) al prezzo di qualche falso allarme in più (precision dal 100% al 97%)
- ▶ I pesi devono riflettere i *costi decisionali*: quanto costa un fido concesso a chi non ripagherà vs. un cliente buono respinto
- ▶ Non le frequenze delle classi

Riepilogo

- ▶ Con classi sbilanciate si usano due prezzi C_- e C_+ per gli scarti
- ▶ Il modello resta un QP convesso
- ▶ Si valuta con precision e recall, non con la sola accuratezza
- ▶ I pesi riflettono i costi decisionali, non le frequenze

Support Vector Regression

Introduzione: Support Vector Regression

- ▶ La stessa idea si applica alla stima di una funzione continua
- ▶ La SVR ignora gli errori entro un tubo di ampiezza ε
- ▶ Solo i punti fuori dal tubo determinano la stima

Il modello SVR

$$\min \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$


con

$$|y_i - (\mathbf{w}'\mathbf{x}_i + b)| \leq \varepsilon + \xi_i^{(*)} \quad \forall i$$

Sulla relazione prezzo–domanda (40 osservazioni):

- ▶ retta SVR: domanda = $-10,86 \cdot \text{prezzo} + 220,32$ (vera: $-11p + 220$)
- ▶ tubo $\varepsilon = 8$: 14 punti su 40 fuori dal tubo $\rightarrow$ solo loro determinano la retta

SVR: solo i punti fuori dal tubo pagano penalità



Come leggere il grafico

- ▶ Le 40 osservazioni della relazione prezzo–domanda
- ▶ La retta stimata e il tubo di tolleranza $\pm \varepsilon = 8$
- ▶ Solo i 14 punti fuori dal tubo pagano penalità e determinano la retta

Riepilogo

- ▶ La SVR stima una funzione continua con un QP convesso
- ▶ Gli errori entro il tubo $\pm\epsilon$ non si pagano
- ▶ Solo i punti fuori dal tubo determinano la retta: sono i support vector della regressione

Esercizi

Introduzione: Esercizi

- ▶ Gli esercizi mettono alla prova i concetti del capitolo
- ▶ Si risolvono a mano o con lo script del laboratorio e Gurobi
- ▶ Toccano hard margin, complementarità, scelta di C , soglia decisionale e One-Class SVM



Esercizio: verifica

- Risolvere a mano l'hard margin con

$$\mathbf{x}_1 = (0, 0), y_1 = -1 \quad \text{e} \quad \mathbf{x}_2 = (4, 0), y_2 = +1$$

- Verificare con Gurobi:

$$\mathbf{w} = (0, 5; 0), \quad b = -1, \quad \text{margine } 4$$

Esercizio: complementarità

- ▶ Per $C = 1$, elencare dallo script i 7 punti con $\alpha_i > 0$
- ▶ Verificare numericamente le tre condizioni di complementarità:

$$\alpha_i = 0 \Rightarrow \xi_i = 0 \text{ e } \text{margine} \geq 1; \quad \text{ecc.}$$

Esercizio: curva di validazione

- ▶ Dividere i 90 clienti in training (60) e validazione (30)
- ▶ Tracciare l'errore di validazione per $C \in \{0,01; 0,1; 1; 10; 100\}$ e scegliere C
- ▶ L'errore di training è monotono in C ? E quello di validazione?

Esercizio: soglia decisionale

- ▶ A parità di modello ($C = 1$), spostare la soglia: classificare insolvente se

$$\mathbf{w}'\mathbf{x} + b < \theta, \quad \theta \in [-1, 1]$$

- ▶ Tracciare precision e recall in funzione di θ
- ▶ Dove sta il punto che massimizza il profitto se un insolvente non individuato costa 10 e un falso allarme 1?

Esercizio: one-class

- Implementare la One-Class SVM sul dataset a corona usando solo i punti normali:

$$\min \frac{1}{2} \|\mathbf{w}\|^2 + \frac{1}{\nu n} \sum_{i=1}^n \xi_i - \rho \quad \text{soggetto a} \quad \mathbf{w}'\phi(\mathbf{x}_i) \geq \rho - \xi_i$$

- Kernel RBF, $\gamma = 0,7$
- Quale frazione di anomalie individua per $\nu \in \{0,05; 0,1; 0,2\}$?

Riepilogo finale (1/2)

Modelli:

- ▶ Hard margin: QP convesso, massimizza il margine $2/\|\mathbf{w}\|$
- ▶ Soft margin: scarti ξ_i pagati C , sempre ammissibile
- ▶ Duale: $\alpha_i \in [0, C]$, $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$

Support vector:

- ▶ Solo i punti con $\alpha_i > 0$ determinano la frontiera
- ▶ La complementarità KKT dice dove sta ciascun punto

Riepilogo finale (2/2)

Estensioni:

- ▶ Kernel: frontiere non lineari da un QP convesso
- ▶ Costi asimmetrici C_- , C_+ per classi sbilanciate
- ▶ SVR: regressione con un tubo di tolleranza $\pm\epsilon$

Scelte del modellista:

- ▶ C e γ con dati di validazione, mai con il test set
- ▶ I pesi riflettono i costi decisionali, non le frequenze